Données à récupérer au CDIF ce soir

Projet QVMM · Applied Investment, HEC Lausanne · Groupe 10
Objectif : repartir avec **tout** ce qu'il faut pour que `main.py` tourne, que les tableaux et figures se génèrent, et que la rédaction du rapport commence ce week-end.

En bref

4 fichiers WRDS à télécharger au CDIF (5 si le CDIF ne propose que l'ancien format CRSP) + **1 fichier gratuit** à télécharger chez toi. Les facteurs de Kenneth French sont déjà dans le projet.

- **1. CRSP mensuel** → `crsp_monthly.csv`
- **2. Compustat annuel** → `compustat.csv`
- **3. Table de liens CRSP-Compustat** → `ccm_link.csv`
- **4. CRSP journalier** → `crsp_daily_AAAA_AAAA.csv` (plusieurs fichiers)
- **(5.) Délistings CRSP**, seulement si l'ancien format → `crsp_delist.csv`
- **Chez toi : facteurs q** → `q5_factors_monthly.csv`

Ordre de priorité si le temps manque : 1 CRSP mensuel → 2 Compustat → 3 Liens → (5 Délistings) → 4 Journalier. Sans le journalier, le code tourne quand même : la volatilité est calculée sur 36 mois de rendements mensuels, et seuls les bêtas de l'analyse des crashs manquent.

1. Avant de partir

Ces cases à cocher te permettent de ne rien oublier.

- ☐ **Clé USB d'au moins 8 Go**, formatée exFAT pour être lisible sur Mac et sur Windows. Le CRSP journalier non compressé peut peser plusieurs Go (estimation) : compresse-le en .zip si le site le propose.
- ☐ **Identifiants WRDS** : ceux du CDIF ou ton compte personnel UNIL.
- ☐ **Ce guide**, sur ton téléphone ou imprimé.
- ☐ Ton Mac chargé, si tu veux tenter l'option A (section 2).
- ☐ Si le prof a donné du code pour lire le format CRSP CIZ, garde-le sous la main pour vérifier les noms de colonnes.

2. Deux façons de récupérer les données

	Option A : script Python	Option B : site web WRDS + clé USB
Quand	Si tu peux te connecter à WRDS en Python depuis ton Mac (réseau UNIL / VPN)	Si l'accès se fait seulement par le site web (cas le plus probable)
Comment	`python code/01_extract_wrds.py --skip-daily` `python code/01_extract_wrds.py --only daily`	Télécharger les 4 tables de la section 3 en CSV, les copier sur la clé
Ensuite	Rien à faire : les fichiers arrivent directement dans `data/raw/`	Section 5 : copier dans `data/raw/csv/` puis lancer `01b_import_csv.py`

Première chose à faire en arrivant : demander au CDIF si l'option A est possible. Sinon, passer directement à l'option B.

3. Les tables à télécharger sur le site WRDS (option B)

Les intitulés des menus WRDS peuvent légèrement varier selon la version du site : en cas de doute, demande au CDIF la table indiquée entre parenthèses. Pour CRSP, **prends le format CIZ (« v2 ») s'il est proposé** : l'ancien format n'est plus mis à jour après 2024.

	1. CRSP mensuel (priorité 1)
Nom du fichier	`crsp_monthly.csv`
Où sur WRDS	CRSP → Stock / Security Files → **Monthly Stock File**, version **CIZ / v2** (table `crsp.msf_v2`)
Période	Janvier 1972 → décembre 2025
Filtres / options	Tous les titres (le code filtre lui-même). Format de sortie : CSV.
Variables (CIZ)	PERMNO, PERMCO, MthCalDt, MthRet, MthRetx, MthPrc, ShrOut, MthCap, MthVol, SICCD, PrimaryExch, ShareType, SecurityType, SecuritySubType, USIncFlg, IssuerType, ConditionalType, TradingStatusFlg, + bid et ask mensuels s'ils sont proposés
Variables (ancien format)	PERMNO, PERMCO, DATE, RET, RETX, PRC, SHROUT, SHRCD, EXCHCD, VOL, BID, ASK, HSICCD
Attention	Vérifier dans la description de la table que MthRet **inclut le rendement de délisting** (c'est le cas en CIZ). Avec l'ancien format, il faut aussi la table 5.

	2. Compustat annuel (priorité 2)
Nom du fichier	`compustat.csv`
Où sur WRDS	Compustat – Capital IQ → North America → **Fundamentals Annual** (table `comp.funda`)
Période	Janvier 1970 → décembre 2025
Filtres / options	Écrans : Consolidation = C, Industry format = INDL, Data format = STD, Population source = D. Identifiant : GVKEY.
Variables	GVKEY, DATADATE, FYEAR, REVT, COGS, XSGA, XINT, SEQ, CEQ, AT, LT, TXDITC, PSTKRV, PSTKL, PSTK
Attention	Ces 15 variables sont toutes indispensables (Operating Profitability et book equity).

	3. Liens CRSP–Compustat (priorité 3)
Nom du fichier	`ccm_link.csv`
Où sur WRDS	CRSP → CRSP/Compustat Merged → **Linking Table** (table `crsp.ccmxpf_linktable`)
Période	Tout l'historique
Filtres / options	Link types : LU et LC. Link primary : P et C.
Variables	GVKEY, LPERMNO, LINKTYPE, LINKPRIM, LINKDT, LINKENDDT

	4. CRSP journalier (priorité 4, le plus lourd)
Nom du fichier	`crsp_daily_1972_1985.csv, crsp_daily_1986_1999.csv, …`
Où sur WRDS	CRSP → Stock / Security Files → **Daily Stock File**, version CIZ / v2 (table `crsp.dsf_v2`)
Période	1972 → 2025, **par tranches d'environ 10 à 15 ans** (un fichier par tranche)
Filtres / options	Compression .zip ou .gz si proposée. Si possible, se limiter aux actions ordinaires pour réduire la taille.
Variables (CIZ)	PERMNO, DlyCalDt, DlyRet **(seulement ces 3 colonnes)**
Variables (ancien format)	PERMNO, DATE, RET
Attention	C'est le téléchargement le plus long : lance-le en dernier. S'il échoue, le reste du projet tourne quand même.

	5. Délistings CRSP (seulement si ancien format)
Nom du fichier	`crsp_delist.csv`
Où sur WRDS	CRSP → **Delisting Information** (table `crsp.msedelist`)
Période	1972 → 2025
Variables	PERMNO, DLSTDT, DLRET
Attention	Inutile si tu as pris le format CIZ. Indispensable sinon, pour éviter le biais de survie.

Options communes à tous les téléchargements

- **Format de sortie** : CSV (« comma-delimited text »). Compressé .zip / .gz accepté.
- **Format des dates** : AAAA-MM-JJ si on te laisse choisir. Les autres formats sont aussi reconnus.
- **Ne pas ouvrir les CSV dans Excel avant de les copier** : Excel peut tronquer les gros fichiers ou modifier les dates.
- Garder les noms de fichiers ci-dessus. Les majuscules et minuscules des colonnes n'ont pas d'importance.

4. À télécharger chez toi (gratuit)

Données	Où	Quoi faire	Statut
Facteurs Fama-French (FF5, Momentum, FF3 journaliers)	Kenneth French Data Library	Rien : déjà téléchargés par le script	✓ fait
Facteurs q (Hou-Xue-Zhang)	global-q.org → Factors	Fichier **q5 factors, monthly** (CSV), renommé `q5_factors_monthly.csv`, dans `data/raw/`	☐ à faire
Facteurs Stambaugh-Yuan	Site de R. Stambaugh (Wharton)	Optionnel, pas encore utilisé par le code	facultatif

5. De retour chez toi : brancher les données au code

Dans VS Code, à la racine du projet `Applied_Investment_Project_Group_10` :

1. Copier les fichiers de la clé dans `data/raw/csv/` (le dossier existe déjà), et les fichiers journaliers dans `data/raw/csv/crsp_daily/`.
2. Ouvrir le terminal et activer l'environnement : `source .venv/bin/activate`
3. Convertir les CSV : `python code/01b_import_csv.py`
4. Tout calculer : `python code/main.py`

```
data/raw/csv/
  crsp_monthly.csv
  crsp_delist.csv            (seulement si ancien format)
  compustat.csv
  ccm_link.csv
  crsp_daily/
    crsp_daily_1972_1985.csv
    crsp_daily_1986_1999.csv
    ...
```

Ce que tu dois voir

Étape	Signe que tout va bien
01b_import_csv.py	« format détecté : CIZ » (ou ancien) ; nombre de lignes et de titres ; journalier : « N années (1972 → 2025) »
02 → 04	de l'ordre de 1 000 à 2 500 titres éligibles par mois selon la décennie (estimation) ; lag des comptes ≥ 6 mois

Étape	Signe que tout va bien
05_portfolios.py	**Contrôle P1 : corrélation avec UMD ≥ 0,8**. Sinon le script s'arrête : c'est voulu
06 → 11	Les tableaux T0 à T11 dans `output/tables/`, les figures F1 à F6 dans `output/figures/`

Si quelque chose bloque

Message	Cause probable	Que faire
« Fichier introuvable »	Mauvais nom ou mauvais dossier	Vérifier les noms de la section 3 et le dossier data/raw/csv/
« variables manquantes »	Une variable non cochée sur WRDS	Retélécharger la table avec la variable, ou m'envoyer la liste des colonnes
« SHRCD et EXCHCD sont indispensables »	Ancien format sans ces colonnes	Retélécharger le CRSP mensuel avec SHRCD et EXCHCD
« aucun rendement de délisting »	Ancien format sans la table 5	Télécharger crsp_delist.csv
« CONTRÔLE RATÉ » (05)	Problème de données ou de timing	M'envoyer le tableau T0 et la sortie de 04

Dans tous les cas, envoie-moi la sortie du terminal : ton dossier est connecté, je peux vérifier les fichiers et corriger directement.

6. Ce week-end : passer au rapport

Une fois `main.py` terminé, chaque section du rapport a ses tableaux et figures prêts, en CSV (pour Excel) et en .tex / .png / .pdf (pour le rapport).

Section du rapport	Tableaux et figures
3. Données	T1 (description), T1b (corrélations), F1 (nombre de titres)
5.1 Tests du cours (H1)	T2a/T2b (déciles), T3 (double tri 3×3), T4 (Fama-MacBeth)
5.2 Horse race	T5 (performance), F2 (richesse cumulée), F3 (drawdowns), F4 (volatilité glissante)
5.3 Alphas et spanning	T6 (alphas CAPM → q), T6b (expositions), T6c (GRS), T7 (spanning)
5.4 Coûts	T8 (coûts et break-even), T8b (demi-spread), F6 (Sharpe net)
6. Robustesse	T9 (sous-périodes), T10 et F5 (crashs), T11 (robustesse)
Annexe / contrôle	T0 (P1 contre UMD)

Résumé pour ce soir : CRSP mensuel, Compustat, liens, journalier (et délistings si ancien format) en CSV sur la clé → `data/raw/csv/` → `01b_import_csv.py` → `main.py`.